

AI Agents & Automation

OpeningGuard

AI Agent 驅動的券商開盤容量決策

提前辨識開盤風險，平衡系統穩定與閒置成本

開盤尖峰，讓傳統擴容慢了一步

- Queue 出現後才擴容，還要等待 30 秒 warmup
- 長期維持高容量，正常時段產生大量閒置成本
- Database 或交易閘道飽和時，增加 worker 也無法解決

📄 **2020 Robinhood**：美股開盤時遇到歷史性流量，基礎設施超載並中斷交易服務。

2016 ASX：主要交易資料庫硬體故障，市場無法準時開盤。

MARKETS

Robinhood goes down again, causing clients to miss out on another historic trading day

PUBLISHED MON, MAR 9 2020 10:18 AM EDT | UPDATED MON, MAR 9 2020 4:03 PM EDT

Maggie Fitzgerald
@MKMFITZGERALD

SHARE f X in ✉

KEY POINTS


- Robinhood experienced another major outage on Monday.
- "Trading is currently down on Robinhood and we're investigating the issue," the Silicon Valley start-up said shortly after the opening bell.
- Robinhood's outage comes after days of technical problems starting Monday, March 2, when clients missed out on the biggest one-day point gain in Dow in history.

TRENDING NOW

-  Trump's state capitalism comes to the oil industry with his unprecedented Venezuela deal
-  Longtime Fox News host Maria Bartiromo disputes reports of termination
-  When someone talks down to you, use Dolly Parton's simple trick to 'maintain your dignity and disarm' them, says expert
-  Trump doubles down on threat to halt trade with top partners unless Fed cuts rates
-  With HSAs, employers are turning to the 401(k) playbook

VIDEO 01:27

Robinhood experiences another round of outages during historic trading day



OpeningGuard 的商業場景與價值

WHY | 為什麼需要

開盤尖峰可能早於反應式擴容生效。長期維持高 worker 又會增加閒置容量成本。

WHO | 誰使用

券商內部的維運、SRE 與容量規劃團隊。系統提供建議，不直接替人員下單或部署。

WHEN | 何時使用

前一晚到開盤前。公開新聞、海外市場波動或營運備註已出現，但 Queue 尚未堆積時。

WHERE | 作用在哪裡

券商下單後端的 API workers、FIFO Queue、Database 與交易閘道容量鏈路。

WHAT | 提供什麼

提前辨識開盤容量風險，比較固定容量、反應式擴容與事件預熱，輸出容量建議及下游瓶頸警告。

HOW | 如何完成

人工標註 few-shot 引導單次 OpenAI Agent 分類 risk_id 與 severity，再由版本化規則模擬容量，並以 Queue-based autoscaling 保底。

商業價值如何驗證

1. 穩定性：SLO 違規率與 Queue 峰值是否下降
2. 成本：正常日 worker-minutes 是否低於長期固定高容量
3. 風險：Agent 漏判、誤報及下游硬上限是否有保底機制

目前為 Synthetic Demo Assumption。正式商業效益需以券商流量、雲端單價與事故成本重新校準。

固定容量浪費，反應式擴容太晚

固定 12 workers

尖峰前已就緒，但正常時段成本高

Reactive Autoscaling

平時成本低，但 Queue 出現後才開始 warmup

OpeningGuard

Agent 提前預熱，Queue autoscaling 負責漏判保底

人工標註建立判斷標準，OpenAI 執行單次分類



人工標註：12 筆 few-shot 用來向模型示範 low、medium、high 的判斷標準，不是重新訓練模型。

獨立驗證：另外保留 15 筆 held-out 案例，不放進 Prompt，只用來計算 accuracy、macro-F1 與 weighted kappa。


Agent 職責界線

Agent 只能選擇既有 risk_id 與 severity，不得產生 RPS、倍率或 worker 數。

不確定性處理

Agent 回傳 uncertain 時，系統以 high 情境進行最壞情況預覽並要求人工確認。

從開盤資訊到容量建議的完整流程



Agent 職責界線：


- 理解非結構化文字並進行風險分類。

規則引擎職責界線：

- 查詢固定參數、計算 worker 數、成本、Queue 與 SLO，不讓 LLM 直接控制容量。


Demo 使用 FastAPI 串接；系統只提供容量建議，不直接部署基礎設施。

8 → 24 → 20 → 8 的容量控制



若利用率重新達到 85%，或 Queue 達到 300，立即重新擴容。55% 與 85% 的雙門檻可避免 worker 反覆開關。

端到端容量取決於最小瓶頸



單一 worker 有效容量

= concurrency slots ÷ 平均服務時間 × efficiency
= 20 ÷ 0.2 × 0.8
= 80 RPS

端到端有效容量

= min (Worker 總容量、Database 上限、交易閘道上限)

12 workers = 960 RPS，不足以處理 1,500 RPS 尖峰。

24 workers = 1,920 RPS，可支撐 worker-only 尖峰。

若 Database 或交易閘道上限只有 1,200 RPS，增加 worker 仍無法解決壅塞。

所有參數皆為 Synthetic Demo Assumption，不代表券商通用常數。

相同預算下的公平實驗

8 cases × 100 seeds × 5 strategies =
4,000 strategy-runs

等量預算

所有策略每小時上限皆為 720 worker-minutes，warmup 也計費

公平比較


同一 case、同一 seed 共用完全相同的流量 trace

全面測試

同時測試早報、晚報、漏報、誤報、長尖峰與下游上限


合成假設：正常 500 RPS、尖峰 1,500 RPS、2 秒 SLO、80 RPS/worker。

提前預熱，避免 Queue 堆積



- Event 策略在尖峰前完成 8 → 24 預熱
- Reactive 策略看到 Queue 後才動作，warmup 期間已產生逾時

合成下單流量如何產生



曲線表示期望到達率；實際每次模擬會在曲線周圍隨機波動。

$$A(t) \sim \text{Poisson}(\lambda(t) \times 0.1)$$

Queue drop、超過 2 秒完成，以及模擬結束仍未完成的請求，全部視為失敗。

- Poisson 為 MVP 合成模型；Hawkes 群聚到達模型列入未來優化。

01

切分時間段

將一小時切成 100 ms 時間區段。

02

產生到達數

每個區段依 Poisson 分布抽取實際到達數。

03

FIFO 隊列

請求依序進入單一 FIFO Queue。

04

延遲計算

檢查每筆委託是否在 2 秒 SLO 內完成。

Monte Carlo 與配對實驗設計

8 種案例 × 100 個 seeds × 5 種策略 =
4,000 strategy-runs

8 種案例

- 正常日
- 提早收到訊號
- 非固定時段尖峰
- 誤報
- 漏報
- 訊號太晚
- 尖峰持續過久
- Database／交易開道硬上限

5 種策略

- Fixed 12
- Scheduled
- Reactive
- OpeningGuard Event
- Perfect Timing


同一個案例與同一個 seed，五種策略使用完全相同的流量 trace，因此可以進行公平的配對比較。

統計方法

- bad-run probability 使用 Wilson 95% 信賴區間。
- 策略差異使用 day-level paired bootstrap 95% 信賴區間。
- 統計單位是模擬日，不是單筆訂單。


相同容量預算下的穩定性與成本結果

OpeningGuard 成功解救的配對案例



三項結果可能來自重疊的 case-seed 配對，不可相加成 400 次獨立案例。

一般低流量日的容量成本



節省：約 33%

成功解救次數來自固定 Agent 情境的容量模擬，用來驗證控制策略，不代表 OpenAI 分類準確率。所有結果皆為合成實驗，不代表真實雲端帳單。

Agent 有效，但不能突破物理上限

訊號太晚

來不及完成 warmup

尖峰太久

24 workers 仍不足

下游飽和

Database／交易閘道成為硬上限

Agent 的價值是爭取提前量，不是創造無限容量。漏判時使用 Queue autoscaling，誤報時仍受 720 worker-minutes 成本上限約束。

從合成驗證到券商內部工具

01

已完成

Agent 事件管線、固定政策、動態擴縮容與 4,000 次合成模擬

03

校準

量測真實 worker、Database、交易開道與 warmup 能力

02

下一步

使用 OpenAI API 跑 15 筆 held-out 人工標註評測，報 accuracy、macro-F1 與 weighted kappa

04

導入

先以券商內部 shadow mode 提供預警與容量建議，不直接自動部署

OpeningGuard 將開盤前事件轉成可稽核的容量準備，在穩定性與閒置成本之間取得可量化的平衡。